Agente de *trading* con RL profundo: DQN, A3C y REINFORCE

Taller de Aprendizaje por Refuerzo (MIAX-14), parte 2 · Iván Nevado, Gonzalo De Ramón y Joseph Egusquiza

1. Qué hemos probado

Seguimos con el mismo entorno de la práctica 1 (estado = tendencia de los últimos 6 precios y posición; 0,1 % de comisión) y los cuatro generadores del enunciado, pero ahora el agente es una **red neuronal** en vez de una tabla. Hemos implementado los dos algoritmos que pide el enunciado, **DQN** y **A3C**, y como ampliación **REINFORCE**, el método de gradiente de la política que vimos en clase. Con los tres cubrimos las tres familias sin modelo: basados en valor, en la política y actor-crítico.

Las tres redes son perceptrones con 2 capas ocultas. Una red admite la tendencia continua, así que ya no discretizamos, pero sí normalizamos: la tendencia se estandariza con la media y la desviación de cada mercado, y la recompensa se divide por la desviación típica de su retorno, para que todos los mercados trabajen en la misma escala. En cada posición solo se consideran las dos acciones que tienen efecto. Cada algoritmo funciona así:

- **DQN:** aprende Q(s, a) con una memoria de 50 000 transiciones, lotes aleatorios y exploración ε-greedy decreciente, una actualización cada 4 pasos. Probamos también **Doble DQN** (una red objetivo que se copia cada k pasos y evalúa la acción que elige la red principal) y **DQN en duelo**, que separa V(s) de la ventaja de cada acción. 200 episodios por entrenamiento.
- **A3C:** 4 procesos juegan en paralelo y actualizan una red compartida sin esperarse. Actor y crítico comparten la red, el retorno es de n pasos (5 a 50) completado con V(s), y la entropía de la política hace el papel de ε. 1500 episodios.
- **REINFORCE:** juega el episodio entero con su política estocástica y sube la probabilidad de cada acción en proporción al retorno completo obtenido, una actualización por episodio. Lo probamos sin y con *baseline* V(s), con la misma red que A3C. 3000 episodios.

Ajustamos α (la tasa de aprendizaje de Adam y su decaimiento), la exploración (ε en DQN, la entropía en A3C y REINFORCE), γ y el tamaño de la red con una búsqueda aleatoria corta (10–16 configuraciones) y una reevaluación de las mejores con el entrenamiento completo y semillas nuevas, solo con las 30 series de validación. El número de episodios lo fijamos con las curvas de aprendizaje. Después entrenamos 5 semillas por algoritmo y mercado y lo evaluamos todo con el protocolo de la práctica 1: las mismas 100 series de test, las mismas métricas y el mismo criterio de convergencia, de modo que los resultados se comparan directamente con los algoritmos tabulares.

Además, probamos la sobreestimación de Q y el periodo de copia de la red objetivo, el número de trabajadores de A3C (1 a 8), la entropía, la política estocástica frente a la *greedy*, un estado ampliado con la volatilidad reciente y la distancia a la media de 20 pasos, la varianza del gradiente de REINFORCE con y sin baseline, y el factor γ^t de la fórmula de REINFORCE de las transparencias.

2. Resultados

Mercado	Agente	Log-ret.	± semillas	Ret. geom. (%)	% series > B&H	Operac.	Conv. (ep.)	ms/ep.	Conv. (s)
	DQN	+6,092	0,182	+44 127,0	98	54,3	60	151	9,1
	Doble DQN	+6,241	0,101	+51 228,3	98	51,0	60	153	9,2
	A3C	+6,412	0,189	+60 830,4	98	29,8	350	25*	8,6
Tendencia + ciclo	REINFORCE	**+6,486**	0,017	+65 517,7	99	30,1	400	23	9,3
	REINFORCE con baseline	+6,456	0,033	+63 541,3	99	31,1	300	23	6,8
	Buy & Hold	+3,316		+2 656,0	—	1,0			
	Aleatorio	+1,558		+375,1	19	164,3			
	DQN	−0,005	0,010	−0,5	50	0,7	80	134	10,7
	Doble DQN	−0,005	0,010	−0,5	50	0,7	80	138	11,0
	A3C	−0,073	0,040	−7,0	38	13,7	800	25*	19,8
Browniano	REINFORCE	**+0,000**	0,000	+0,0	51	0,0	300	23	7,0
	REINFORCE con baseline	+0,000	0,000	+0,0	51	0,0	300	21	6,4
	Buy & Hold	−0,062		−6,0	—	1,0			
	Aleatorio	−0,187		−17,1	37	164,3			
	DQN	+0,175	0,045	+19,1	83	47,5	160	146	23,3
	Doble DQN	**+0,201**	0,020	+22,2	86	40,7	180	161	29,0
	A3C	+0,114	0,044	+12,0	75	37,2	750	67*	50,5
Reversión a la media	REINFORCE	+0,053	0,064	+5,4	60	12,7	1 700	23	39,7
	REINFORCE con baseline	+0,085	0,066	+8,9	73	14,5	2 300	24	54,6
	Buy & Hold	−0,005		−0,5	—	1,0			
	Aleatorio	−0,169		−15,6	24	164,3			
	DQN	**+0,030**	0,040	+3,0	64	8,7	140	135	18,8
	Doble DQN	+0,008	0,011	+0,8	64	17,8	180	147	26,4
	A3C	+0,000	0,000	+0,0	58	0,0	150	28*	4,1
Regímenes	REINFORCE	+0,000	0,000	+0,0	58	0,0	300	23	6,8
	REINFORCE con baseline	+0,000	0,000	+0,0	58	0,0	300	23	6,8
	Buy & Hold	−0,128		−12,0	—	1,0			
	Aleatorio	−0,220		−19,7	36	164,3			

Tabla 1. Resultados en test (100 series por mercado; en los algoritmos, media de 5 semillas). En negrita, el mejor algoritmo de cada mercado. ± semillas: desviación del log-retorno entre semillas. Conv.: episodios hasta converger (mediana de las semillas) y su equivalente en segundos. *A3C: ms de reloj con 4 procesos en paralelo (4 veces más de CPU).

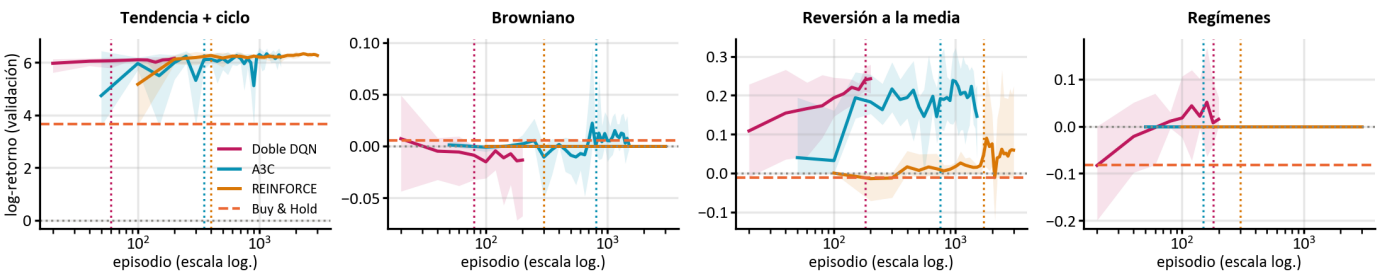


Figura 1. Curvas de aprendizaje: log-retorno medio de la política *greedy* en validación (media y rango de 5 semillas; episodios en escala logarítmica). Las líneas verticales punteadas marcan dónde converge cada algoritmo.

3. Análisis

Estrategias aprendidas (Fig. 2). Donde hay señal, las tres redes aprenden lo mismo que las tablas. En **tendencia + ciclo** todas aprenden *momentum* con histéresis (compran con tendencia claramente positiva y aguantan hasta que es claramente negativa) y ganan a *buy & hold* en el 97–99 % de las series. En **reversión a la media** aprenden a comprar tras caídas fuertes, aunque con más dispersión entre semillas. En el **browniano** lo correcto es no operar: REINFORCE no opera nunca y DQN casi nunca (−0,5 %), mientras que A3C sigue invertido gran parte del tiempo y pierde un 7 %, más que el propio *buy & hold* (−6 %). En **regímenes** DQN y Doble DQN sacan una pequeña ganancia (+3 % y +0,8 %); A3C y REINFORCE se quedan fuera.

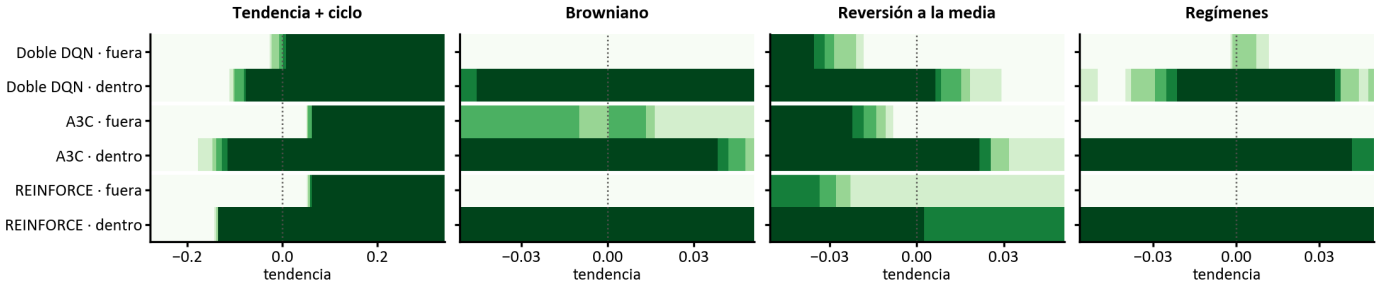


Figura 2. Política aprendida: fracción de las 5 semillas que quedan invertidas después de actuar, según la tendencia. En la fila «fuera», verde significa que compra; en la fila «dentro», verde significa que mantiene y blanco que vende.

Hiperparámetros. Se repite la lección de la práctica 1: casi todos los ajustes eligen γ bajo o medio (0–0,9) y una tasa de aprendizaje pequeña y decreciente, porque la recompensa de cada paso es casi todo ruido. En REINFORCE se ve muy claro: con γ = 0,99 el resultado en tendencia + ciclo cae de 6,49 a 2,80 (Tabla 2), por la varianza del retorno completo, igual que le pasaba a Monte Carlo. La exploración importa menos: en A3C la entropía apenas cambia el resultado, y en REINFORCE ayuda algo más mantenerla alta.

Variante	Tendencia + ciclo	Browniano	Reversión a la media	Regímenes
Variantes y extensiones de la práctica 2				
DQN en duelo	+6,193	+0,000	+0,189	+0,026
Doble DQN en duelo	+6,260	+0,000	+0,197	+0,014
Doble DQN con estado ampliado	+6,609	−0,019	+0,273	+0,130
A3C con estado ampliado	+6,694	−0,070	+0,316	+0,000
REINFORCE con γ = 0,99 (1500 ep.)	+2,801	+0,000	+0,001	+0,000
REINFORCE con baseline y γ = 0,99 (1500 ep.)	+3,177	+0,000	+0,014	+0,000
REINFORCE con baseline y factor γ^t (1500 ep.)	+1,622	+0,000	+0,032	−0,235
Algoritmos tabulares de la práctica 1				
Q-Learning	+6,338	+0,000	+0,155	+0,040
SARSA	+6,316	+0,000	+0,203	+0,000
Monte Carlo	+6,522	−0,012	+0,238	+0,031
Q-Learning con estado ampliado	+6,579	−0,006	+0,317	+0,154

Tabla 2. Variantes, extensiones y algoritmos tabulares de la práctica 1: log-retorno medio en test (mismo protocolo que la Tabla 1). Los experimentos de REINFORCE marcados se hicieron con 1500 episodios y 2 semillas.

Lo que enseñan las variantes. Doble DQN no cambia la media, pero reduce a la mitad la variación entre semillas (por ejemplo, de 0,182 a 0,101 en tendencia). Medimos que DQN sobreestima Q, pero casi todo lo corrige la red objetivo y no cambia la política. El duelo no aporta con solo 3 acciones. En A3C, más trabajadores reducen el tiempo de reloj hasta unas 2 veces, pero no mejoran el aprendizaje. En REINFORCE, el *baseline* reduce 2,4 veces la varianza del gradiente con γ = 0,99, pero nada con los γ cortos que elige el ajuste, así que las dos variantes rinden parecido. Por último, aplicar el factor γ^t de las transparencias hunde el resultado (de 6,58 a 1,62 en tendencia): con γ = 0 el agente solo aprendería del primer paso de cada episodio.

Convergencia y coste. DQN es el que menos episodios necesita (60–180), porque reutiliza cada experiencia muchas veces, pero cada episodio cuesta 134–204 ms. A3C y REINFORCE necesitan cientos o miles de episodios más baratos (unos 23–67 ms). En segundos, los algoritmos tabulares de la práctica 1 siguen siendo los más rápidos: 2–5 s en tendencia + ciclo frente a 7–9 s de las redes, y 14–19 s frente a 23–55 s en reversión.

4. Conclusiones

Las tres redes aprenden la estrategia esperada en los mercados con señal y ganan a *buy & hold* y al agente aleatorio, con la excepción de A3C en el browniano. Sus mejores resultados son 6,49 en tendencia + ciclo (REINFORCE, el más estable entre semillas) y +0,201 en reversión (Doble DQN).

Con un estado de solo dos variables, **ninguna red mejora a los algoritmos tabulares** de la práctica 1 (Monte Carlo: 6,52 y 0,238), y cuestan más cómputo. La ventaja de una red aparece cuando el estado crece: con la volatilidad y la distancia a la media, A3C sube a 6,69 en tendencia y Doble DQN a 0,27 en reversión y 0,13 en regímenes, sin discretizar nada. Igual que en la primera parte, importan más la información del estado y la elección de α y γ que el algoritmo concreto.

Entre familias, los métodos de gradiente de la política (A3C y REINFORCE) son los que peor aprovechan la señal débil de reversión, y junto con SARSA son los que se quedan fuera en regímenes. Como **limitaciones**: los mercados son sintéticos, las búsquedas de hiperparámetros fueron cortas, cada algoritmo usa un número distinto de episodios, A3C no es reproducible exactamente por su asincronía, y con 5 semillas las diferencias pequeñas no son concluyentes.