TALLER DE APRENDIZAJE POR REFUERZO · MIAX-14

Agente de trading con RL tabular

Q-Learning, SARSA y Monte Carlo sobre cuatro mercados sintéticos

Q-Learning SARSA Monte Carlo

Iván Nevado · Gonzalo De Ramón · Joseph Egusquiza

Entorno y algoritmos

SimpleTradingEnv

Estado

Tendencia de los últimos 6 precios y posición

Acciones

Vender, mantener o comprar

Coste

0,1 % de comisión en cada operación

Mercados

Los cuatro generadores del enunciado, con series de 500 precios

Q-Learning

TD · off-policy

Objetivo: r + γ · max Q(s', a')

SARSA

TD · on-policy

Objetivo: r + γ · Q(s', a'), a' por ε-greedy

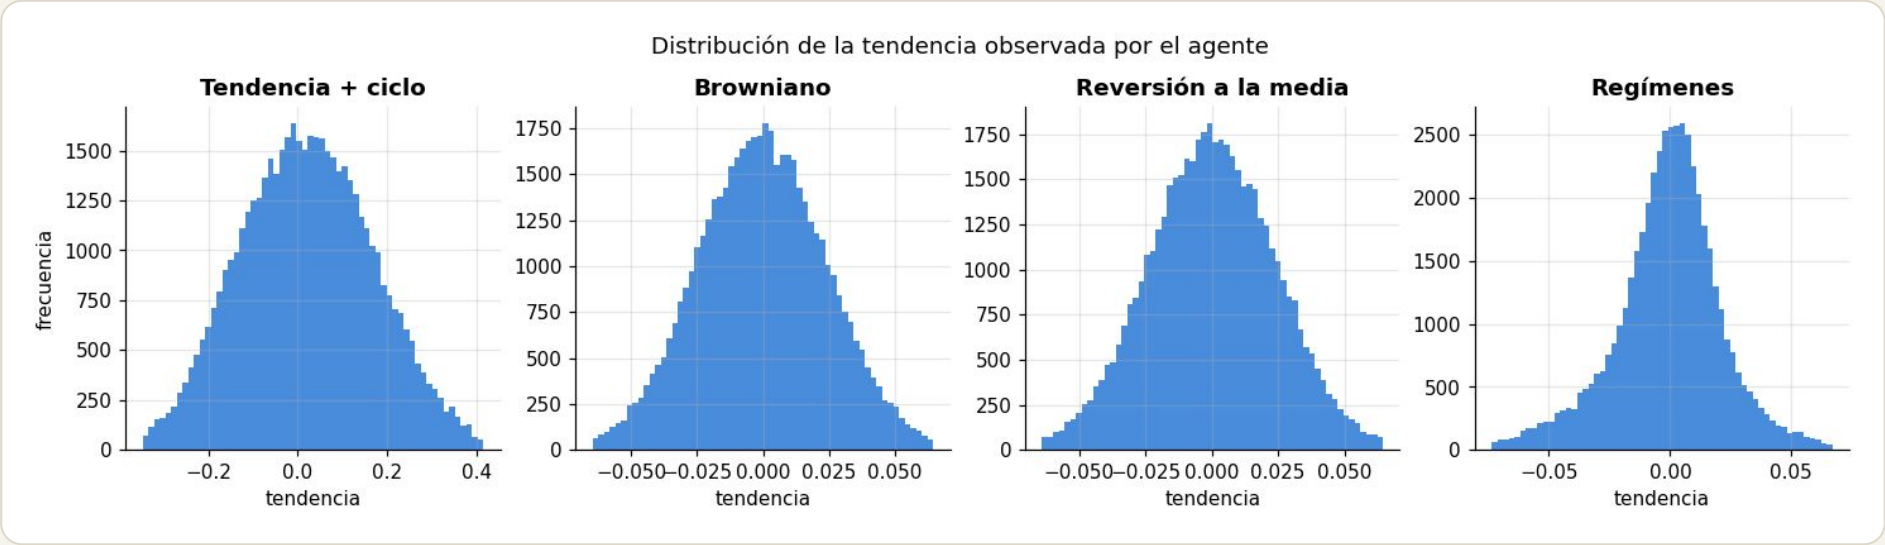
Monte Carlo

extra · on-policy, ε-greedy

Objetivo: el retorno completo del episodio

Monte Carlo es un extra: lo añadimos para comprobar en un caso real la comparación entre *bootstrapping* (TD) y retorno completo (MC) del tema 3.

Discretización por cuantiles



Una rejilla uniforme no sirve

Según el generador, la tendencia se mueve en ±0,03 o en ±0,3: casi todos los datos caerían en uno o dos intervalos.

Cuantiles por generador

Los límites se calculan para cada generador, y el número de intervalos (de 5 a 25) es un hiperparámetro más.

Estado = (intervalo, posición)

Los algoritmos son tabulares: hay que discretizar la tendencia. Cada episodio usa una serie nueva de 500 precios.

Ajuste de hiperparámetros

Solo hemos usado 30 series de validación, con el log-retorno medio de la política *greedy* como criterio. Cada algoritmo tiene su propia búsqueda.

Q-Learning

396 entrenamientos

Rejilla con α = {0,01; 0,05; 0,2}, γ = {0; 0,5; 0,9; 0,99} y 5, 10 o 20 intervalos; después, ε.

SARSA

40 configuraciones

Búsqueda aleatoria con α decreciente y reevaluación de las 3 mejores. Solo considera las acciones con efecto en cada posición.

Monte Carlo

696 entrenamientos

Otra rejilla, con α más pequeños (hasta 0,001 y 1/N), comparando además *every-visit* y *first-visit*.

Con las curvas de aprendizaje fijamos 3000 episodios y entrenamos 5 semillas por algoritmo y mercado.

Protocolo común de evaluación

Al juntar los resultados vimos que Q-Learning y SARSA no se habían evaluado con las mismas series de test ni con las mismas métricas, así que repetimos la evaluación con un protocolo común.

Series de test

Las mismas 100 por mercado, que no se han usado para ajustar nada.

Métrica principal

Log-retorno medio del capital: la media del balance la dominan unas pocas series.

Convergencia

Primer episodio a partir del cual la curva de validación ya no sale de una banda alrededor de su valor final. En segundos: episodios × coste de un episodio (8–11 ms, medido en serie en el mismo ordenador).

Referencias

Agente aleatorio, *buy & hold*, no invertir nunca y dos reglas fijas: *momentum* y *contrarian*.

Rendimiento en test

Los tres algoritmos ganan a *buy & hold* y al agente aleatorio en los cuatro mercados; en el browniano, quedándose fuera.

Mejores resultados: 6,5 en tendencia + ciclo y +24 % en reversión (Monte Carlo), y +4 % en regímenes (Q-Learning).

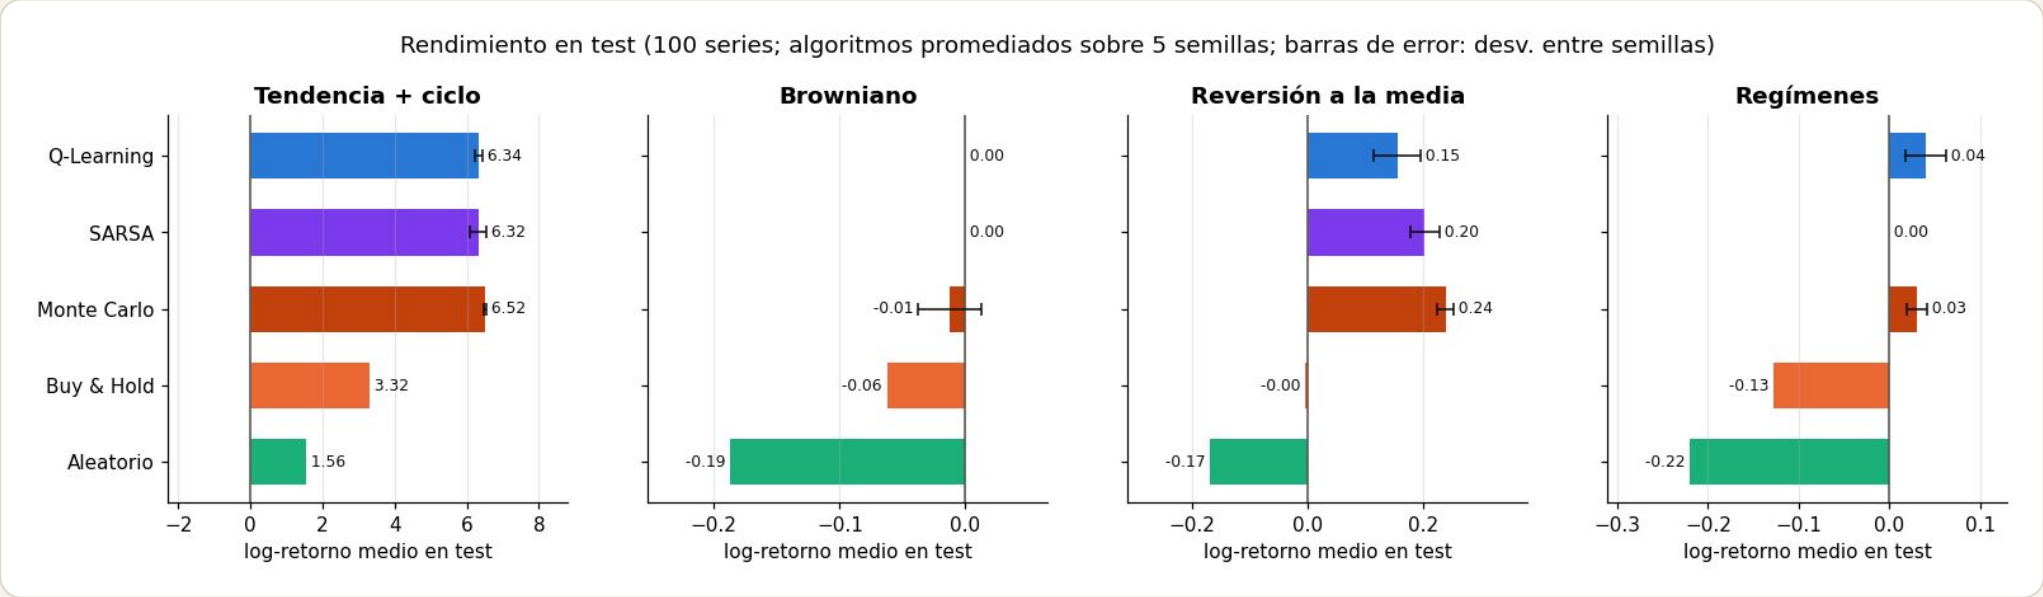


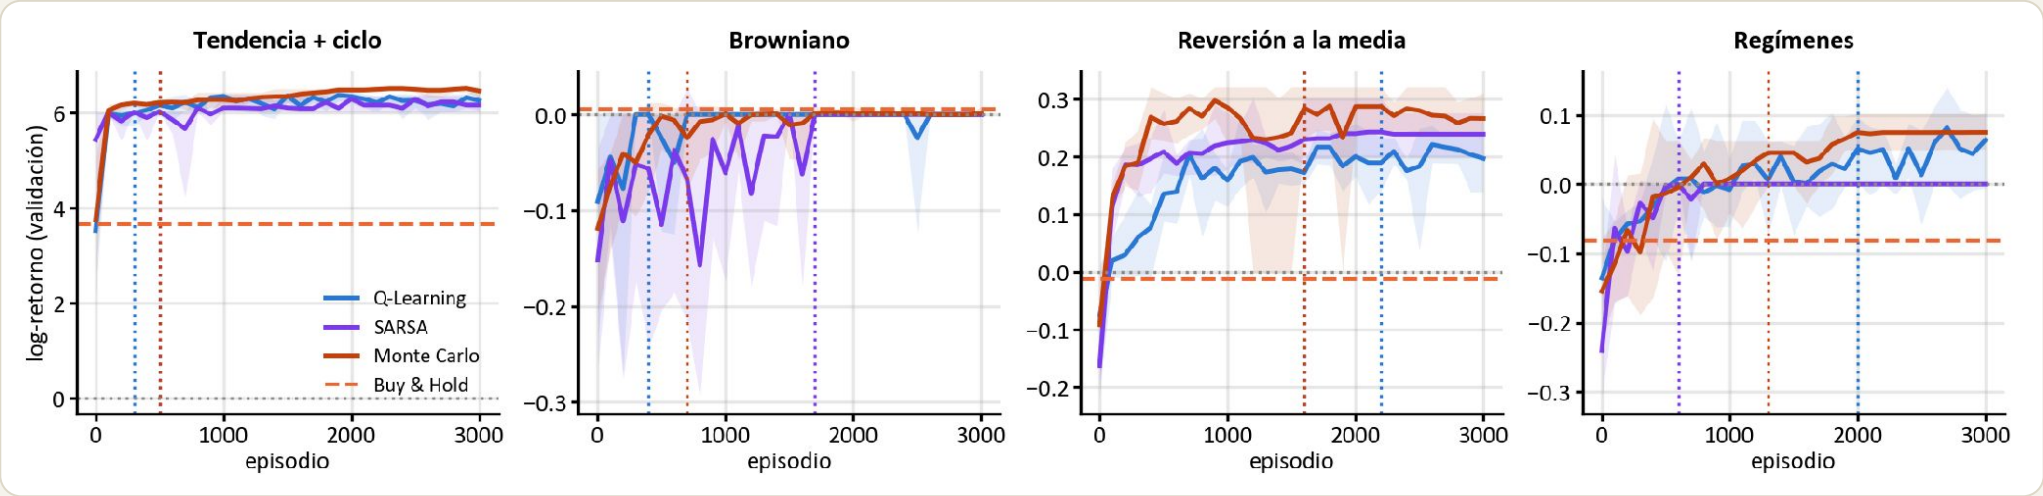
Tabla 1 · Tendencia + ciclo y Browniano

Mercado	Agente	Log-ret.	Ret. geom. (%)	% series > B&H	Sharpe	DD máx. (%)	Operac.	Conv. (ep.)	Conv. (s)
Tendencia + ciclo	Q-Learning	+6,338	+56 472,6	96	3,11	63,3	57,8	300	2,4
	SARSA	+6,316	+55 244,5	97	3,14	61,5	47,0	500	4,0
	Monte Carlo	**+6,522**	+67 892,2	97	3,21	61,4	39,5	500	4,8
	Buy & Hold	+3,316	+2 656,0	—	1,86	90,3	1,0	—	—
	Aleatorio	+1,558	+375,1	19	1,27	80,4	164,3	—	—
Browniano	Q-Learning	**+0,000**	+0,0	51	0,00	0,0	0,0	400	4,2
	SARSA	**+0,000**	+0,0	51	0,00	0,0	0,0	1 700	13,0
	Monte Carlo	−0,012	−1,2	49	0,01	8,3	0,2	700	6,5
	Buy & Hold	−0,062	−6,0	—	0,06	41,9	1,0	—	—
	Aleatorio	−0,187	−17,1	37	−0,31	36,0	164,3	—	—

Tabla 1 · Reversión a la media y Regímenes

Mercado	Agente	Log-ret.	Ret. geom. (%)	% series > B&H	Sharpe	DD máx. (%)	Operac.	Conv. (ep.)	Conv. (s)
Reversión a la media	Q-Learning	+0,155	+16,7	80	0,55	16,8	52,7	2 200	18,6
	SARSA	+0,203	+22,5	89	0,69	15,7	25,1	1 600	14,1
	Monte Carlo	**+0,238**	+26,9	90	0,75	16,4	21,5	1 600	17,3
	Buy & Hold	−0,005	−0,5	—	0,15	25,7	1,0	—	—
	Aleatorio	−0,169	−15,6	24	−0,26	31,9	164,3	—	—
Regímenes	Q-Learning	**+0,040**	+4,0	69	0,22	22,9	45,6	2 000	16,6
	SARSA	+0,000	+0,0	58	0,00	0,0	0,0	600	5,5
	Monte Carlo	+0,031	+3,1	67	0,19	25,1	38,6	1 300	11,5
	Buy & Hold	−0,128	−12,0	—	−0,04	43,7	1,0	—	—
	Aleatorio	−0,220	−19,7	36	−0,42	35,4	164,3	—	—

Curvas de aprendizaje y convergencia



Depende del mercado

Señal fuerte: 300–500 episodios (2–5 s).

Señal débil (reversión y regímenes): 1300–2200 episodios (11–19 s).

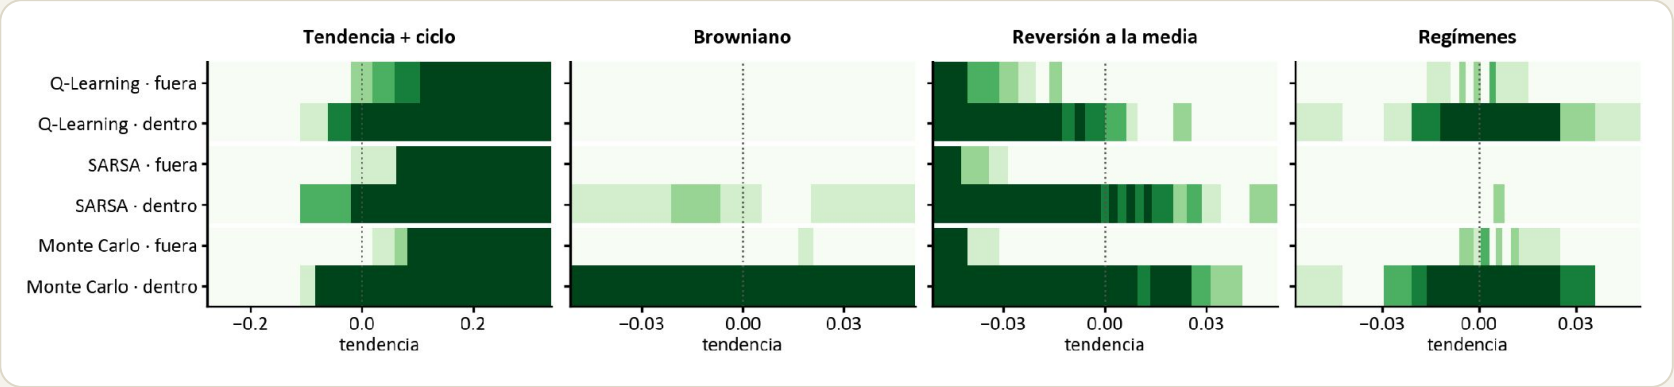
SARSA en regímenes

Converge rápido (600 episodios) porque converge a no operar.

Coste por episodio

Casi igual en los tres (8–11 ms)

Estrategias aprendidas



Verde: compra (fila «fuera») o mantiene (fila «dentro»). El hueco entre ambas filas es la histéresis.

Tendencia + ciclo

Momentum. Compran con tendencia positiva y venden solo con tendencia claramente negativa.

Browniano

Quedarse fuera. Nada que aprender. Q-Learning y SARSA no operan; Monte Carlo pierde un 1,2 % (ruido).

Reversión a la media

Contrarian. Compran tras caídas fuertes y venden al recuperarse

Regímenes

Salir ante movimientos bruscos. El más difícil. Q-Learning y MC, 3–4 %; SARSA no opera; *buy & hold*, −12 %.

Hiperparámetros

El que más influye

$\alpha \geq 0{,}05$

y la mayoría de los agentes de reversión y regímenes acaban sin operar. La recompensa de cada paso es casi todo ruido: el precio se mueve un 1–10 % por paso y la señal es de décimas de punto.

Con γ los algoritmos no coinciden

3–7,5×

más ruidoso es el retorno completo que una recompensa suelta con γ = 0,99, la desventaja de MC frente a TD. Por eso Monte Carlo prefiere γ = 0 en tres de los cuatro mercados; Q-Learning necesita 0,99 en reversión y regímenes.

Con γ = 0 no se pierde la histéresis, porque ya la crea la comisión: el agente compra si espera ganar más que ella y vende si espera perder más. El número de intervalos y el calendario de ε importan bastante menos, y en Monte Carlo *every-visit* funciona mejor que *first-visit*.

Experimentos de control y extensiones

Variante	Tendencia + ciclo	Browniano	Reversión a la media	Regímenes
Q-Learning (base)	+6,338	+0,000	+0,155	+0,040
Q-Learning con hiperparámetros de MC	+6,517	+0,000	+0,222	+0,077
Monte Carlo	+6,522	−0,012	+0,238	+0,031
SARSA (base)	+6,316	+0,000	+0,203	+0,000
SARSA con hiperparámetros de Q-Learning	+6,311	+0,000	+0,099	+0,000
Double Q-Learning	+6,414	+0,000	+0,188	+0,018
Q-Learning con estado ampliado	+6,579	−0,006	+0,317	+0,154

Estado ampliado (volatilidad reciente y distancia a la media de 20 pasos): la mayor mejora, +37 % en reversión y +17 % en regímenes.

Double Q-Learning no se distingue del ruido entre semillas.

¿Algoritmo o hiperparámetros?

Como cada algoritmo se ajustó con una búsqueda distinta, no estaba claro de dónde venían las diferencias, así que intercambiamos hiperparámetros entre algoritmos.

Q-Learning con los hiperparámetros de MC

6,517 ≈ 6,522

log-retorno en tendencia + ciclo: Q-Learning con los hiperparámetros de MC y Monte Carlo

La ventaja venía de α = 0,001, un valor que no entraba en la rejilla de Q-Learning; además, con γ = 0 los dos algoritmos tienen el mismo objetivo.

SARSA sí tiene una diferencia propia

0,099 vs 0,155

reversión a la media, SARSA frente a Q-Learning con los mismos hiperparámetros (en regímenes: 0 frente a 0,040)

SARSA es *on-policy* y aprende el valor de la política ε-greedy que sigue. Explorar es comprar y vender al azar pagando comisión: con señal débil, le compensa no hacer nada.

Conclusiones y limitaciones

Ganan a las referencias. Los tres algoritmos ganan a *buy & hold* y al aleatorio en todos los mercados (en el browniano, quedándose fuera) y aprenden la estrategia esperada.

Mejores resultados. 6,5 en tendencia + ciclo y +27 % en reversión (Monte Carlo), y +4 % en regímenes (Q-Learning).

El algoritmo importa menos que la información del estado (el estado ampliado mejora más que cualquier cambio de algoritmo) y que α y γ.

On-policy frente a off-policy es la única diferencia estable: SARSA es más conservador y deja pasar señales débiles que Q-Learning aprovecha. Monte Carlo funciona porque usa γ = 0 en tres de los cuatro mercados y esquiva la varianza del retorno.

Limitaciones

Mercados sintéticos con parámetros conocidos y entorno de todo o nada con comisión fija.

Discretización calibrada con datos del mismo generador.

Solo 5 semillas: las diferencias pequeñas entre algoritmos no son concluyentes.